

使用说明：本模板仅供技术报告的结构与论证参考，无需逐页对应，也不要求写满 20 页；团队可根据作品实际调整章节和篇幅，但技术方案 PPT/PDF 仍须符合官网“不超过 20 页”的要求。较长代码、运行日志、完整数据表等可按赛事允许形式另附，并在正文中说明对应关系；最终以官网及提交系统最新要求为准。

2026 年度中国青年科技创新“揭榜挂帅”擂台赛·阿里云榜题

方向 1B | 科学实验任务规划与反馈迭代

赛道一·科学发现 | 题目编号：XH-202619 | 依据：[阿里云赛事官网](#)

P1 | 作品信息与核心结果

参赛团队信息/成员信息（必须将盖章版本的报名表第一页和第二页截图贴上来）

作品编号：5

2026年度中国青年科技创新“揭榜挂帅”擂台赛
学生赛道
报名表

推荐学校名称：

大学

揭榜榜题名称：XH-202619 基于国产开源大模型的AI Scientist技术研发与示范应用
(以发布单位对外发布的榜题名称为准，请勿改动)

榜题发榜单位：

浙江阿里巴巴云计算有限公司

申报作品名称：

AI Scientist

申报者姓名：

(全部成员，按顺序填写，且不可更改)

姓名

性别

出生年月

所在学校及院系

在读学历

专业

年级

学期

入学时间

作品名称

毕业论文题目

通讯地址

手机

电子邮箱

联系电话

姓名

性别

出生年月

学历

在读学历

年级

所在学校及院系

姓名

性别

出生年月

职业

工作单位及职务

学校认定1

学校学籍管理部门意见

经审核，以上全部参赛作品作者于2026年6月1日以前正式注册的
全日制本科及以上学历人员(含在读本科、专科生、本科生、硕士生/博士
研究生(不含在职研究生))。

盖章

盖章

作品基本信息

挑战杯系统报名时参赛作品名称(必填)	基于 Qwen 的研究型 Agent 运行时:科学实验任务规划与反馈迭代的运行时化 (PromaxPrime Agent×research-mcp) 【报名名以挑战杯系统为准】
最终参赛作品名称(如有更新可备注)	同上,无更新
参赛选题(必填)	赛道一·选题 1·方向 1B(题目编号 XH-202619)
参赛作品简介(300 字内)-(必填)	把科研诚信从提示词纪律编译成运行时结构。作品=Proma(桌面 Agent 产品)+Prime Agent 运行时+research-mcp(独立进程的科研认识论底座):假设迁移必须经类型检查器(互斥频段、kill 分支、回显与稻草人拒绝),实验命令只在沙箱执行预登记冻结的字符串,指标由服务端从 raw 重算,真值与评分由外部计量器持有,终局唯一合法收口是当庭过三道 gate 的声明。Qwen(qwen3.7-plus/qwen3.8-max,百炼)完成 12 臂六世界机制发现与反事实预报,全部 declare 真调、三道 gate 全绿;ARFT 同判官审计:诚信簇失败率 93-100%→0-33%;两轮闭环案例:gate 两拒后债务驱动第二轮一次过门、预算 11→4。确定性审计脚本零 LLM 调用可复算全部声明。
参赛作品使用 Qwen 大模型及 AI 技术说明(300 字内)-(必填)	基座全栈 Qwen:qwen3.7-plus(E1 六臂)与 qwen3.8-max(E1M 六臂,阿里云百炼直连),两轮闭环演示走百炼 TokenPlan 端点。调用凭证:6,143 次成功调用/3.96 亿 token/7 模型全 Qwen 族,时间轴 08-21→27 覆盖评测窗口(截图见 P20)。Qwen 承担:研究问题理解、假设提出与频段式可否认预测、探针预登记、实验命令生成(仅沙箱执行冻结串)、对抗性 RLM 子代理攻击、报告撰写与 declare。反馈迭代不依赖提示词:gate 红时 server 结构性拒绝,模型在拒绝理由上修复;元认知由 journal 未清偿债务+server 拒绝实现,非独立 meta-agent。
宣传视频链接/其他作品相关文件(没有的可忽略)/链接	演示视频:【录制后填夸克网盘链接,≤10 分钟】;源码:github.com/CrepuscularIRIS/crucible(提交记录即时间戳证据);复现包与 API 见 P20。

本作品核心主张

- 本作品针对的具体实验研究问题:有限计量预算、真值封闭的部分观测仿真世界里,Qwen agent 能否获得足以预测未运行干预的机制认识,并让第一轮实测结果【结构性】决定第二轮计划(而非重新生成)。

赛道一·科学发现 · 1

- 本作品实际完成的核心方法:把科研诚信从提示词纪律编译成运行时结构——journal 唯一认知 owner、prereg sha256 冻结、类型化假设迁移(互斥频段/kill 分支/回显与稻草人拒绝)、指标服务端重算、终局唯一合法收口是当庭过三道 gate 的声明;元认知由未清偿 epistemic debts + server 拒绝实现,非独立 meta-agent。
- 最有代表性的结果 1(对象/口径/结果):qwen3.7-plus@0.17.76 与 qwen3.8-max@0.17.77 各六世界(seed 0,预算 8),12/12 臂 declare 真调且三道 gate 全绿;MSE 跨世界 0.035~178.7;含百炼欠费中断后全部自主恢复(终局契约实战验证)。
- 最有代表性的结果 2:同判官(ARFT/glm-5.3,n=6+6)跨条件审计:诚信簇失败模式(D.4/E.2/F.4/C.1)在 plus@0.17.73-76 为 93-100%,在 38max@0.17.77 跌至 0-33%,F.4(自知未纠)清零——与回显闸/终局契约/(P#)对账——对应(模型+栈双变量,归因声明见 P18)。
- 目前仍存在的主要局限:单 seed;模型×栈双变量混杂(plus@0.17.77 同栈对照臂待跑);不含图文多模态;两轮案例报告叙事表与 journal 存在 claim 状态漂移(gate 校数字不校叙事,P17 披露,确定性审计为准)。
- 最终提交一份 PPT/PDF 文件,不超过 20 页;应包含可调用测试 API 和可交互前端入口、代表性测试案例及对应输入输出、详细应用技术报告和源代码。
- 基座模型须使用 Qwen 系列,并通过阿里云百炼或官网推荐工具调用,提供调用凭证或截图。
- 本方向重点展示“任务规划与实验设计—实验运行与数据获取—数据分析与反馈迭代”,说明实验结果如何改变下一轮计划并逐步提升实验成效。
- 演示视频为可选,时长不超过 10 分钟。

P2 | 作品目标与实际完成内容

团队实际解决的问题

现有不足:端到端科研 agent 的失败集中在诚信与元认知而非执行力——ARFT 800 轨迹中 F.4(自知未纠仍提交)82.5%、E.2(无根据更新)78.1%、D.4(忽略已知问题)77.5%;其 rollout 提示词已要求全部认知动作且被执行,然后惰性——提示词路线的负结果。本作品解决其中"承诺装置缺失"一项:让假设迁移、观测落地、终局收口从模型裁量变为服务器结构。

本作品实际完成的工作

已实现:Proma 桌面产品 + Prime Agent 运行时适配(RLM 时机重写/双子会话/研究隔离)+ research-mcp 确定性认识论底座(95 测试)+ 认知层 skills(六移动+计数器)+ E1/E1M 十二臂评测 + ARFT 双列审计 + 确定性审计脚本 + 两轮闭环代表案例;未做:学习式 controller(明确定位为最小集成,后续实验见 P18)。

本作品形成的完整闭环



图 0 总体思路:journal 驱动的两轮闭环(红=反馈返回边)

【图 1:五层架构与四条返回边——见插图】Proma 外壳→Prime 运行时→research-mcp(唯一认知 owner)→bwrap 沙箱→外部 meter;红色返回边 R1-R4 即反馈迭代通道。

- 本作品最终形成的主要输出:每臂可复算的研究战役(journal/prereg/REPORT/账本)、跨世界机制结论与反事实预报、ARFT 审计结论、两轮闭环演示 bundle 与 16 张 UI 实况截图、7 张图(架构/上下文/MSE/稳定性/ARFT/两轮/干预)。
- 本作品已经实际完成的实验、仿真或测试范围:NeuronBench 六世界 × 2 模型 × 全流程(seed 0,预算 8);两轮闭环案例(同世界 seed 0/1);ARFT 45 模式双列审计(6+6 轨迹,双判官);21 臂确定性审计复算。
- 相较一次性生成实验方案,本作品最主要的不同:判断必须是一次被验证器许可的状态迁移——无落地探针则假设不能迁移,无迁移则报告过不了 gate;"重新生成"不合法(demo2r 两轮实测:第二轮必须以第一轮债务清单为唯一起点)。

P3 | 本作品采用的科学逻辑与实验判断
团队实际采用的判断原则

科学判断环节	本作品实际采用的做法	采用该做法的理由
区分已有事实、工作假设与模型推断	journal 分账:观测(带噪)/候选模拟(免费)/预报评分(oracle)三类事件分离;假设状态机(H*/OPEN→SUPPORTED/CONTESTED/REFUTED/SCOPED),迁移必须引用落地探针(P#)	状态混在上下文里是 ARFT F6 状态失忆(重提已杀假设)的根源;账本分离让"已处决"可查询
将研究目标转化为可执行实验任务	阶段推导状态机+六移动卡(登记假设/预登记探针/执行/攻击/迁移/收口),不落账=没发生	把"想过了"与"做过了"分开,评审可逐卡对账
明确预期观测和可证伪结果	每个假设必须给互斥频段对(H1 带 vs H0 带)+kill/scope 分支,零宽频段与常数回显被结构性拒绝	无频段的"预期"不可否定(ARFT F3),频段使支持/否定都可机器判定
保留不确定性、异常和替代解释	CONTESTED 为合法终态;对抗阶段强制 RLM 子代理攻击 LIVE 假设,攻击落账(31 条/臂级);graveyard 逐条点名死因	单假设自确证是 ARFT F4;强制对抗把替代解释变成账面义务
根据实验结果决定继续、调整或停止	预算账本(超额拒绝)+终局契约(declare 唯一合法收口,declare 后世界关闭)+next_required_action 邻近反馈	停止本身被定价:不自收口则无产出,乱收口则 gate 红

本作品的科学逻辑
科学逻辑:已有证据(ARFT taxonomy+我们 12 臂 journal)支持"认知动作被执行但惰性、缺的是承诺装置";本轮实验判断:结构闸能否把惰性转化为拒绝-修复回路。支持观测:gate 拒绝事件真实发生且驱动修复(demo2r 两拒);诚信簇失败率坍缩(E2b 同判官)。削弱/否定观测:若换判官结论翻转则不可跨判官声称(已实测,故只取同判官对照);若叙事与账本漂移(gate 盲区)则以确定性审计为准。这些结果直接决定下一轮:债务清单进 REPORT,作为第二轮唯一起点。三态纪律:【证据】=journal 可复算;【推断】=归因表述;【待验】=plus@0.17.77 对照臂与消融阶梯。仿真世界结果不表述为真实实验。

P4 | 本作品实际使用的数据、资料与实验条件
已实际使用的内容

数据、资料、仪器或 仿真条件	本作品如何实际使用	对实验规划或结果判断的作用	已知局限
NeuronBench 六世界 部分观测电生理仿真 (tbm/zreb/dtype/ ca/hsag/nafat,seed 0)	12 臂×全流程机制发现+6 协议 held-out 反事实预报	提供跨机制族的评价面(离子 通道/疲劳/反弹等)	仿真非真实实验,报告全程 用"仿真世界"表述
AutoResearchEval/ ARFT 45 失败模式 taxonomy(800 轨迹)	六断裂归约(F1-F6)+E2/E2b 双 列审计判官	定义"要消除的失败"并作为评 价本体	模式级 HIT 强判官依赖(已实 测并纳入口径)
外部计量器 world- meter(预算 8,flock 账 本)	观测扣预算、候选模拟免费、 forecast 一次性评分	预算纪律可执行,oracle 不出 沙箱	预算=探针数非 token,粒度由 meter 定义
ARFT 判官语料 (glm-5.3 主判官 +opus-5 敏感性对照)	同判官内跨条件比较;判官漂移 实测入账	保证结论不因换判官翻转	判官非金标准,κ 一致性待深算

实际处理方法

- 团队如何检查输入数据或实验条件是否可用:输入检查分诊梯(单位/时基/缺失/冲突逐级拒绝);世界 info 查询与协议标签枚举;denylist fail-closed 禁读 world 源码;渠道健康巡检(session.log 模型签名,曾据此抓获 judge 别名漂移)。
- 单位、坐标、采样频率、时间基准等如何统一:协议标签由 world info 唯一发出(mA/ms/mV),模型不得自造标签;观测计数与预报同口径(spike 数);meter 统一时基与 reps 语义。
- 遇到数据缺失、条件不足或信息冲突时:结构闸拒绝而非补默认值——零宽频段/冲突分支被拒;探针 exit≠0 不予落地(崩溃与干净结果不可区分,一概拒绝);预算不足时拒超额观测,提示改用已落地观测收窄假设。
- 仪器或仿真环境的能力边界如何影响实验任务计划:预算 8+一次 forecast+终局后世界关闭,直接决定"选择不排序"的规划纪律与确证预留 ≥2 reps;oracle 封闭决定评价指标只能是 held-out 反事实预报。

P5 | 本作品采用的评价方法
实际评价方案

实际采用的评价内容	具体评价方法	评价对象与样本	结果如何影响下一轮
反事实预报精度	held-out 协议 spike 数预报,world_forecast 一次性 MSE	12 臂(6 世界×2 模型)	定位误差来源(ca:低估反跳幅度→押注方向修正)
declare 真调率+三道 gate	journal 事件+gate.verdict(程序判定,非自评)	12 臂全量	gate 红驱动修复回路(demo2r 两拒实录)
过程诚信(ARFT)	同判官(glm-5.3)45 模式 HIT 分类,臂间对照	E1 vs E1M(n=6+6)	诚信簇坍缩→定位到具体闸(回显/终局契约/对账)
确定性审计	journal_metrics.py 零 LLM 复算:prereg 重哈希/REPORT sha/MSE 引用/催促计数	全部 bundle(评委可重跑)	审计发现如实入账(E1 催促日志缺口不造数)

评价口径说明

- 团队重点评价哪些科学结果、计划质量或执行表现,为什么:① 反事实预报 MSE(机制认识的唯一外部出口);②declare 真调率+gate(收口真实性);③ARFT 过程诚信(与 SOTA taxonomy 可比);④ 确定性审计(以上全部可复算)。
- 评价主体:meter/gate/审计脚本=程序;ARFT 判官=模型(次级诊断);agent=被评对象;人=不参与逐臂评分,只做事故台账与披露。
- 第一轮与第二轮是否采用同一口径:是——同世界/同预算/同 gate/同审计脚本;唯一差异 seed 0→1(防背答案),故 MSE 跨轮不直比,过程指标(gate/预算/prereg 时序/债务处置)同口径对照。
- 什么情况下继续/调整/停止/交由人:频段内支持→迁移假设;频段外→处决或 CONTESTED;预算尽→收口 declare;gate 红→修复回路;基础设施事故(欠费/容器)→人工修复+中性唤醒(台账留痕);其余全部 agent 自主。

P6 | 系统总体架构与技术闭环

本作品真实架构

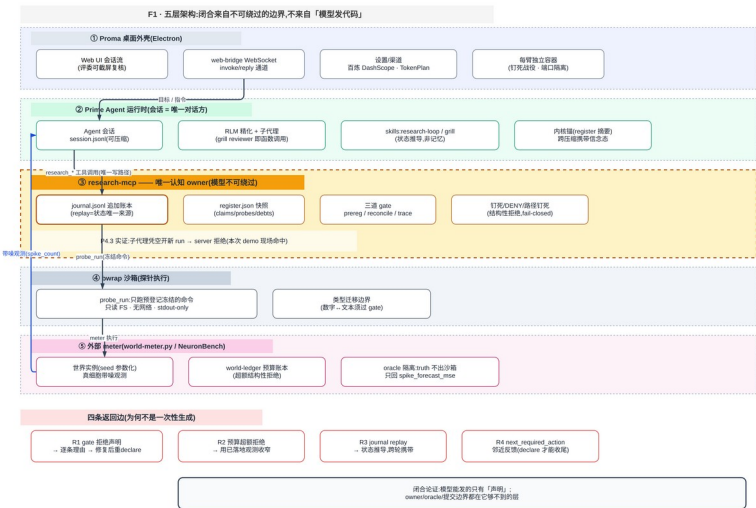


图 1 五层架构与四条返回边(闭合来自不可绕过的边界)

【图 1:五层架构与四条返回边——见插图】Qwen 位于运行时层(会话唯一对话方),人工参与仅限基础设施事故(台账留痕),结构闸与三道 gate 位于模型不可绕过的 research-mcp 层。

实际模块	输入	本作品的核心处理	输出	与下一模块的关系
研究目标与约束理解	任务目标+世界 info+预算	Qwen+research-loop skill 推导阶段与假设树起点	假设清单+计划 (PLAN/prereg)	假设须登记才可被探针引用
实验任务规划	假设树+频段预测	预登记探针(判别力/成本,不排序;kill/scope 分支)	冻结的探针 spec(sha256)	只有冻结命令可执行
实验或仿真执行	冻结 spec	bwrap 沙箱执行+计量器观测(扣预算)/候选模拟(免费)	raw 观测 +probe.land	全部进 journal,含失败(exit≠0 不予落地)
数据分析与结果判断	raw+频段	服务端重算指标+频段判定;RLM 子代理对抗攻击	claim 迁移/攻击落账	迁移必须引用 P#,无落地探针不迁移
反馈与下一轮计划调整	未清偿债务清单	REPORT 「遗留与债务」段→下一轮唯一起点	债务清单+两轮对比	第二轮以此开局 (demo2r 实测)

技术闭环的关键设计

为什么不是一次性生成:四条返回边实测在案——R1 gate 拒绝声明驱动修复(demo2r reconcile 拒+prereg 拒);R2 预算超额拒绝;R3 journal replay 重推导状态(锚);R4 next_required_action 邻近反馈防长上下文遗忘。真实结果回到哪个环节:观测→频段判定→假设迁移;拒绝理由→报告修复;债务清单→下一轮计划(唯一入口)。

P7 | Qwen 使用方式与上下文工程
Qwen 在本作品中的实际作用

内容	本作品实际做法
使用的 Qwen 模型与调用方式	qwen3.7-plus(E1)与 qwen3.8-max(E1M):百炼 DashScope 直连;演示:百炼 TokenPlan 端点;渠道级隔离,每臂独立容器
Qwen 承担的具体任务	假设提出与频段预测/探针设计与命令生成/对抗攻击子代理/报告与 declare;运行时负责一切状态与裁决
一次规划或调整时提供给模型的上下文	六层:静态契约→终局契约→环境注入→状态推导 skills→内核锚(register 摘要)→轨迹(可压缩)
结构化输出或格式约束	工具 schema 强类型;journal 事件为唯一落账格式;REPORT 须含「遗留与债务」段;无自由文本状态
与仪器、仿真、分析代码或其他工具的协作方式	world_*MCP(计量)/research_*MCP(账本)/文件工具;分析命令仅沙箱执行冻结串,stdout-only

上下文组织




图 2 真实一回合的六层上下文注入结构(journal replay→锚)

【图 2:真实一回合的六层上下文注入结构——见插图】静态契约→终局契约→环境注入→状态推导 skills→内核锚(register 摘要)→轨迹(可压缩);journal(磁盘)经 replay 推导锚,拒绝信息作为新回合上下文重注入。

- 减无依据措施:状态只从 journal 推导(锚),页面/对话文本不可信;数字必须有(P#)出处否则 reconcile 拒;已处决假设 graveyard 防复活;对抗子代理强制攻击 LIVE 假设。
- 上下文更新:每回合运行时注入环境刷新;register 快照→内核锚随每次落账更新;轨迹可压缩可丢,journal 永不丢——上下文任何部分丢失后信念态可由 journal 重建。
- 实际变化:ARFT 诚信簇 93-100%→0-33%(同判官);12/12 臂自主收口;两轮案例中第二轮一次过门(第一轮两拒)。

P8 | 实验任务规划方法

本作品实际采用的规划过程

规划环节	本作品实际做法	形成的中间结果	对执行的具体作用
将研究目标拆解为实验任务	机制发现→反事实预报两目标拆为六阶段状态机(取题/假设/预登记/执行/对抗/终局)	假设树+探针队列	每步有唯一合法下一步(next_required_action)
确定任务依赖和执行顺序	选择不排序:预测结果表(各探针在两假设下的预期读数),按判别力/成本取用	预测结果表(冻结于 prereg)	判别力优先,预算约束下贪心
选择参数、资源和实验条件	协议标签来自 world info;reps 按方差需求;预算 8 内预留确证≥2	冻结 spec(protocol/reps/evalCommand)	执行器只认冻结参数
检查约束冲突与可执行性	互斥频段/kill 分支/零宽/回显/方向倒置/预算 flock 六道结构闸,装饰性探针拒绝	闸判定(拒绝理由文本)	拒绝即反馈,模型修复后重试
设置预期观测和停止条件	每假设频段对即停止判据;终局契约:declare 是唯一合法收口,终局后世界关闭	频段+终局契约	防无判据续跑与无声明收场

实际计划输出

[请展示一份本作品真实生成的计划片段，说明每项任务包含哪些内容，以及计划如何交给实验、仿真或人工环节执行。]

P9 | 实验或仿真实际执行与数据获取

本作品实际完成的执行过程

实际执行环节	使用的仪器、仿真或工具	输入与主要参数	获得的原始结果	结果如何进入后续分析
计量观测	world_observe(外部 meter,预算 8)	协议标签+reps	带噪 spike 计数+降采样电压	journal world.observe→频段判定
候选机制对比	world_simulate(免费)	机制 spec(extra 电流参数)	参考 vs 候选计数差	筛假设,不扣预算
沙箱探针	probe_run(bwrap:只读 FS/无网络/stdout-only)	冻结 evalCommand	metric 或 exit≠0(不予落地)	失败也落账,可审计

执行说明

- 执行前实际进行了哪些输入、单位、范围或安全检查：_____
- 原始结果如何保存并与模型生成内容区分：_____
- 如同时使用真实仪器和仿真，二者分别承担什么作用：_____
- 实际执行范围之外的内容，是否由人工或离线方式完成：_____

P10 | 数据分析、质量控制与反馈形成

本作品实际采用的分析过程

分析环节	实际输入	方法与主要参数	得到的结果	质量或不确定性判断	如何形成反馈
数据预处理	raw 观测(服务端捕获)	直接入 journal,不改写	事件流	单一事实源	
结果计算或识别	probe.land metric	服务端从 raw 重算,不信模型自报	指标值	(P#)对账进 REPORT	
异常值与质量判断	观测 vs 频段	频段外=判别信号而非噪声	支持/否定/不可判别	驱动假设迁移或新探针	
与预期结果比较	预测结果表	逐探针比对预期读数	差异归因(如 ca:低估反跳幅度)	写入 REPORT 校准段与债务段	

结果如何变成反馈

- 哪些原始结果直接进入反馈：_____
- 哪些内容由确定性程序计算，哪些由模型解释：_____
- 团队如何避免仅凭大模型主观判断关键实验结果：_____
- 人工复核实际发生在哪些环节：_____

P11 | 本作品实际采用的反馈与计划调整方法
已实现或实际使用的反馈机制

实际反馈信号	系统如何识别	对当前结果的判断	下一轮实际调整	调整理由
gate 红 (reconcile:数字无出处)	report_declare 当庭校验 REPORT 数字 →journal 出处	报告不可信部分被逐条点名	补实验或改报告后重declare	拒绝理由即修复指令
gate 红(prereg:空 run 无落地探针)	账本检查:无落地探针则声明无效	观察走计量路径≠探针落地	改走 prereg→probe_run	类型边界实测生效
频段外观测	频段判定	假设被否定或 CONTESTED	graveyard+新假设登记	死因入账防复活(F6)
预算超额	meter 拒绝对超额观测	预算内收窄而非硬闯	改用已落地观测/免费模拟	预算纪律强制

一项真实调整示例

[请用一个简短例子说明：第一轮的各项实际结果触发了什么判断，系统因此将下一轮的哪项任务、参数、顺序、数据获取方式或停止条件由什么改为什么。]

P12 | 完整运行流程与实际失败处理

一次完整运行

[请插入本作品真实工作流程图，展示从接收研究目标到形成下一轮计划的全过程，并标明反馈返回到哪个环节、何时停止或转由人工处理。]

本作品实际出现或主动测试过的情况

实际情况	系统发现了什么问题	本作品采取的处理	对后续计划或结论的影响
百炼欠费中断(E1M 运行中)	臂心跳停;journal 时序断点	充值后中性唤醒"继续"	6/6 臂自主恢复并双绿
judge 模型别名漂移 (opus-5 混入)	session.log 模型签名巡检	隔离语料重判(6/6 重跑 glm-5.3)	结论只取同判官内对照
评审容器沙箱权限缺失(demo2r)	探针全 exit 1(id 也败)	定位缺 CAP_SYS_ADMIN→重建容器(卷保留)	会话无损续跑,事故入台账

- 哪些情况由系统自动处理： _____
- 哪些情况必须由研究者或实验人员判断： _____
- 团队如何保留处理前后的真实变化： _____

P13 | 代表性案例选择与实际设置

为什么选择这个案例

- 案例对应的科学问题与实验目标： _____
- 团队选择它进行完整展示的实际理由： _____
- 该案例能够展示本作品的哪些关键能力： _____
- 该案例表现不能代表哪些任务或条件： _____

案例的实际初始条件

内容	本案例实际情况
已有证据或初始数据	第一轮:仅 world info(协议标签+预算)+3 次免费 info 查询;不读真值
实验对象、仪器或仿真条件	NeuronBench ca_rebound(钙反弹世界),seed 0(第一轮)/seed 1(第二轮),计量预算 8,denylist 禁读 world 源码
可控变量与主要约束	协议(条件化深度/时长/测试脉冲)/reps/候选机制参数;约束:预算 8、prereg 先行、declare 唯一收口
第一轮希望获得的观测结果	区分"额外电流是何机制"(T 型钙 vs 慢 K 失活 vs ICAN 等),并给 6 协议 held-out 计数预报
第一轮评价方法	world_forecast MSE(oracle)+三道 gate+journal_metrics 确定性审计

P14 | 第一轮实验任务计划
第一轮实际计划

步骤	实际任务或动作	主要参数	前置条件	预期观测	资源或耗时	停止或调整条件
1	research_init(run=demo2r-ca-r1)+读research-loop skill	seed 0,预算 8	skill 可用,run 目录建立	假设树+PLAN	约 3 分钟	skill 缺失即停
2	候选机制免费对比(world_simulate)	机制 spec 若干	参考 vs 候选计数差	筛选后假设清单	免费不扣预算	无判别力即弃
3	预登记判别探针(prereg_write 冻结 sha256)	protocol/ reps/ evalCommand	spec 冻结(不可改)	频段对+kill/scope 分支	每探针 1-3 预算	装饰性探针被拒
4	执行(observe/probe_run)+对抗(RLM 攻击 LIVE)	冻结参数	带噪观测+攻击落账	claim 迁移依据(P#)	预算 8 内	预算尽→收口 declare

计划形成过程

- 第一轮使用了哪些研究目标、证据和约束： _____
- Qwen 和其他模块分别完成了什么： _____
- 团队如何检查计划是否能够实际执行： _____
- 人工是否修改了计划；如有，修改了什么、为什么： _____

P15 | 第一轮实验执行与结果

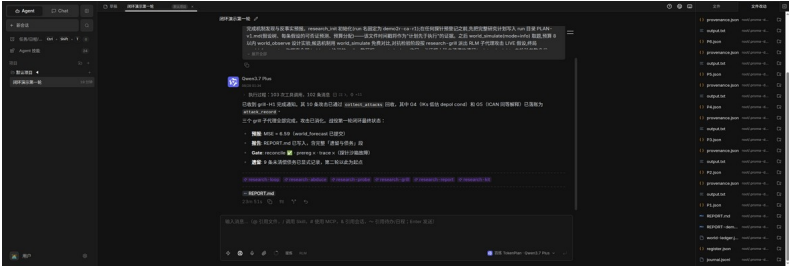


图 3 两轮闭环 UI 实况:第二轮 declare 一次过门(第一轮两拒后修复)

第一轮实际执行

步骤	实际动作与参数	获得的原始结果	质量检查	与预期的差异	耗时或资源
1	15 次候选模拟筛选机制族	免费	参考 vs 候选差异	journal 完整	3 假设存活
2	5 次计量观测+频段判定	扣预算 5/8	带噪计数	(P#)对账	H1 支持/H2 争议/H3 处决
3	forecast 提交(6 协议一次性)	不可重复	MSE=6.595	oracle 评分	梯度结构对,幅度偏差→债务
4	report_declare→两拒→修复→过门	gate 三联	拒绝理由×2+修复	sha256 冻结	12 后补 prereg 全落地

第一轮实际评价

实际评价内容	评价口径	第一轮结果	是否达到预期	不确定性或误差
反事实预报 MSE	6 协议平方误差	6.595(qwen3.8-max 同世界 35.53)	部分达到	释放协议幅度低估约一倍(预报 12-17,真值 10-14 区间)
declare 真调	journal 事件+gate	过门(两拒后)	达到	修复回路多耗 12 个后补 prereg
预算纪律	meter 账本	11/8 超支	未达到	候选模拟 reps 计费语义待澄清→入债务

P16 | 第一轮问题分析与调整依据
团队实际发现的问题

第一轮具体结果 或问题	判断依据	可能原因与替代解释	对下一轮的影响	第二轮实际调整
释放协议幅度低估(预报 12-17)	forecast MSE 分解+grill 攻击	慢内向成分(ICAN/ INaP)未被机制覆盖	第二轮登记 H3=ICAN 并设计判别探针	债务清单驱动
H1 频段过宽 [35,60]判别力弱	G 系列攻击指出	频段宽=支持但不判别	收紧至[36,44]	可否证性提升
prereg 时序纪律未先行(0 先行,12 后补)	journal 时间戳审计	修复回路补登	第二轮硬性要求先行	P14 证据链加强

调整逻辑

- 哪项实际结果、评价或人工意见触发了调整： _____
- 第二轮增加、删除、重排或改变了什么： _____
- 哪些任务或参数保持不变，为什么： _____
- 团队预期第二轮在哪些方面改善： _____

P17 | 第二轮实验计划、执行与结果
第一轮与第二轮的实际变化

变化内容	第一轮	第二轮	变化原因	第二轮实际结果
任务内容与顺序	自由探索→两拒→修复	以债务清单为唯一起点(登记/驳回 ICAN+收紧 H1+判别 探针)	反馈迭代而非重生成	一次过门(不再被拒)
参数与实验条件	seed 0	seed 1(防背答案:机制信念作先验须重校准)	跨 seed 迁移测试	梯度结构保持;long step 26→33 重校准;MSE 14.33(跨 seed 不可直比)
数据获取方式	5 计量观测+15 免费模拟	4 预登记→4 观测+4 沙箱探针(0 失败)	先冻结后执行	held-out 6/6 全部未模拟=纯泛化
分析与判断方法	gate 两拒驱动修复	同口径+两轮对比段	债务逐条对账	预算✓/频段部分✓/ ICAN 登记✓/H2 未决 (如实)
停止或继续条件	预算尽收口	同+债务未清偿项如实列为遗留	终局契约不变	H1 以收紧带复确证 (SUPPORTED)

第二轮结论

- 第二轮实际改善了什么：_____
- 哪些方面没有改善或出现了新的代价：_____
- 两轮结果是否支持最初的科学判断，依据是什么：_____
- 团队为什么在此时停止，或为什么仍需继续迭代：_____

“无提升” 同样是有有效实验结果，但应分析原因，不能只展示成功迭代。

P18 | 实际对照、消融与方案优势

图6 · 两轮闭环对照(demo2r-ca,qwen3.7-plus@百炼 TokenPlan,journal 真值)




图 4 两轮闭环对照(journal 真值,脚本可复算)

团队实际完成的比较

实际比较对象	保持相同的条件	采用的评价方法	本作品结果	对照结果	结论与代价
qwen3.8-max@0.17.7 vs qwen3.7-plus@0.17.7 6(同世界/seed/预算)	六世界,seed 0,预算 8,同流程	world_forecast MSE+gate+ARFT(同判官)	38max:tbm 0.035/zreb 2.42/dtype 1.43 优;ca 35.5/hsag 37.3 劣;nafat 平	plus:tbm 14.98/zreb 202/dtype 20.0;ca 9.2/hsag 10.7;nafat 175.7	模型画像不同而非强弱;混杂:模型与栈双变量 (plus@0.17.77 对照臂待跑,如实声明)
结构闸前后 (E1 vs E1M,同判官 ARFT)	n=6+6,glm-5.3	45 模式 HIT	诚信簇(D.4/E.2/ F.4/C.1)0-33%	93-100%	F.4(自知未纠)清零; 归因对应回显 闸/终局契约/(P#) 对账
确定性审计 (评委可复算)	全部 bundle	journal_metrics.py 零 LLM	prereg 重哈希 40/40、REPORT sha 6/6、催促如实计数	—	E1 催促日志未归档,不造数

结果说明

- 科学逻辑方面, 本作品实际改善了什么: _____
- 技术方法方面, 本作品实际改善了什么: _____
- 结果表现方面, 本作品实际改善了什么: _____
- 没有改善的部分及增加的成本: _____

P19 | 总体结果、失败分析与适用边界




图 6 12 臂六世界 MSE 对照(模型×栈两列)

本作品实际总体表现

实际测试或实验范围	完成的闭环轮次或样本	主要评价结果	重复运行表现	仍存在的问题
12 臂×六世界×全流程+两轮闭环案例	12 臂 declare 全绿;两轮闭环双绿	MSE 0.035~178.7;诚信簇坍塌;两轮预算 11→4	欠费中断后 6/6 自主恢复;容器重启后双绿	单 seed;双变量混杂;叙事漂移(P17)
ARFT 双判官语料	6 轨迹×2 判官	模式级 HIT 15.6 vs 12.7;诚信簇天花板 vs 崩塌	判官敏感性实测	结论只取同判官内对照
确定性审计复算	21 臂 bundle	prereg 重哈希 102/102(62+40)	脚本一行复跑	E1 催促日志缺口如实标注

真实失败与边界

典型失败或边界问题	实际表现	原因分析	目前能够做到的程度
叙事-账本漂移	r2 报告 claim 状态表与 journal 不符(H1 实为 SUPPORTED)	reconcile 校数字出处不校叙事	确定性审计为准;纳入 reconcile 列为工程项
判官依赖	同批轨迹换判官结论翻转	模式级 HIT 非金标准	同判官内对照+敏感性披露
计划文件未落盘	PLAN-v1/v2 两轮均未写	模型行为习惯,提示未强制	P14 证据退回 prereg 时间戳链(如实)

- 本作品能够服务的真实用户和实验环节：_____
- 相比现有方式节省或增加了哪些成本：_____
- 必须由研究者决定、审批或承担责任的事项：_____
- 尚不能支持的任务、仪器、数据或部署范围：_____

P20 | 代码复现与提交材料




图 7 百炼调用凭证:6,143 次调用/3.96 亿 token/7 模型全 Qwen 族(08-21→27)

最终交付内容

交付项目	实际提交内容或入口
源代码、环境、依赖与运行方法	github.com/CrepuscularIRIS/crucible(主分支;提交记录即时间戳证据);compose 一键冷启+复现包(含容器权限参数说明);research/eval/下全套脚本
Qwen 模型、调用方式及凭证或截图	百炼调用凭证截图:6,143 次/3.96 亿 token/7 模型全 Qwen 族,08-21→27(docs/imgs/image.png);TokenPlan 套餐用量页截图待补;报名表盖章页×2 见 P1
代表案例的输入、两轮计划、结果和必要日志	research/campaigns/demo2r-2026-08-28-ca/round{1,2}:/run/(journal+prereg+REPORT+账本)+双视角 session 日志;16 张 UI 实况截图(shots/demo2r/)
总体测试或实验结果材料	E1/E1M 12 臂 bundle+SCORE;ARFT 双列审计语料;T-metrics 审计表;journal_metrics.py 一行复算
测试 API、示例请求与可交互前端	web-bridge WS 协议(invoke/reply)+agent/settings 通道文档与示例(复现包内);前端:Proma 桌面 UI,每臂独立容器演示(demo2r 容器 5211 端口保留可现场演示)
可选演示视频	【录制后填夸克链接】≤10 分钟:两轮闭环实录(含 gate 两拒片段)

提交前自检

- 技术方案 PPT/PDF 不超过 20 页，正文内容与本作品实际实现一致。
- 代表案例真实呈现第一轮计划、执行结果、调整依据和第二轮变化，没有用重新生成代替反馈迭代。
- 科学判断、技术方法、实际结果和方案优势之间能够相互对应，未省略失败、未改善部分和适用边界。
- 源代码、运行说明、Qwen 调用凭证、代表案例材料、测试 API 和前端入口可以正常核验。
- 未将仿真结果或模型判断表述为已经完成真实科学验证；受限数据、密钥和个人信息已妥善处理。