

P1 | 作品信息与核心结果

参赛团队信息/成员信息（必须将盖章版本的报名表第一页和第二页截图贴上来）

【待贴:报名表盖章页第一页 / 第二页截图 ×2 —— 已备槽位,用户持有】



图0 总体思路:journal 驱动的两轮闭环(红=反馈返回边)

作品基本信息

| 挑战杯系统报名时参赛作品名称(必填)               | 基于Qwen的研究型Agent运行时:科学实验任务规划与反馈迭代的运行时化(Proma×Prime Agent×research-mcp)【报名名以挑战杯系统为准】                                                                                                                                                                                                                                                                       |
|----------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 最终参赛作品名称(如有更新可备注)                | 同上,无更新                                                                                                                                                                                                                                                                                                                                                   |
| 参赛选题(必填)                         | 赛道一 · 选题1 · 方向1B(题目编号 XH-202619)                                                                                                                                                                                                                                                                                                                         |
| 参赛作品简介(300字内)-(必填)               | 把科研诚信从提示词纪律编译成运行时结构。作品=Proma(桌面Agent产品)+Prime Agent运行时+research-mcp(独立进程的科研认识论底座):假设迁移必须经类型检查器(互斥频段、kill分支、回显与稻草人拒绝),实验命令只在沙箱执行预登记冻结的字符串,指标由服务端从raw重算,真值与评分由外部计量器持有,终局唯一合法收口是当庭过三道gate的声明。Qwen(qwen3.7-plus/qwen3.8-max,百炼)完成12臂六世界机制发现与反事实实预报,全部declare真调、三道gate全绿;ARFT同判官审计:诚信簇失败率93-100%→0-33%;两轮闭环案例:gate两拒后债务驱动第二轮一次过门、预算11→4。确定性审计脚本零LLM调用可复算全部声明。 |
| 参赛作品使用Qwen大模型及AI技术说明(300字内)-(必填) | 基座全栈Qwen:qwen3.7-plus(E1六臂)与qwen3.8-max(E1M六臂,阿里云百炼直连),两轮闭环演示走百炼TokenPlan端点。调用凭证:6,143次成功调用/3.96亿token/7模型全Qwen族,时间轴08-21→27覆盖评测窗口(截图见P20)。Qwen承担:研究问题理解、假设提出与频段式可否证预测、探针预登记、实验命令生成(仅沙箱执行冻结串)、对抗性RLM子代理攻击、报告撰写与declare。反馈迭代不依赖提示词:gate红时server结构性拒绝,模型在拒绝理由上修复;元认知由journal未清偿债务+server拒绝实现,非独立meta-agent。                                                |
| 宣传视频链接/其他作品相关文件(没有的可忽略)链接        | 演示视频:【录制后填夸克网盘链接,≤10分钟】;源码:github.com/CrepuscularIRIS/crucible(提交记录即时戳证据);复现包与API见P20。                                                                                                                                                                                                                                                                   |

本作品核心主张

本作品针对的具体实验研究问题:有限计量预算、真值封闭的部分观测仿真世界里,Qwen agent 能否获得足以预测未运行干预的机制认识,并让第一轮实测结果【结构性】决定第二轮计划(而非重新生成)。

本作品实际完成的核心方法:把科研诚信从提示词纪律编译成运行时结构——journal 唯一认知 owner、prereg sha256 冻结、类型化假设迁移(互斥频段/kill分支/回显与稻草人拒绝)、指标服务端重算、终局唯一合法收口是当庭过三道 gate 的声明;元认知由未清偿 epistemic debts + server 拒绝实现,非独立 meta-agent。

最有代表性的结果1(对象/口径/结果):qwen3.7-plus@0.17.76 与 qwen3.8-max@0.17.77 各六世界(seed 0,预算 8),12/12 臂 declare 真调且三道 gate 全绿;MSE 跨世界 0.035~178.7;含百炼欠费中断后全部自主恢复(终局契约实战验证)。

最有代表性的结果2:同判官(ARFT/glm-5.3,n=6+6)跨条件审计:诚信簇失败模式(D.4/E.2/F.4/C.1)在 plus@0.17.73-76 为 93-100%,在 38max@0.17.77 跌至 0-33%,F.4(自知未纠)清零——与回显闸/终局契约/(P#)对账——对应(模型+栈双变量,归因声明见 P18)。

目前仍存在的主要局限:单 seed;模型×栈双变量混杂(plus@0.17.77 同栈对照臂待跑);不含图文多模态;两轮案例报告叙事表与 journal 存在 claim 状态漂移(gate 校数字不校叙事,P17 披露,确定性审计为准)。

最终提交一份PPT/PDF文件,不超过20页;应包含可调用测试API和可交互前端入口、代表性测试案例及对应输入输出、详细应用技术报告和源代码。

基座模型须使用Qwen系列,并通过阿里云百炼或官网推荐工具调用,提供调用凭证或截图。

本方向重点展示“任务规划与实验设计—实验运行与数据获取—数据分析与反馈迭代”，说明实验结果如何改变下一轮计划并逐步提升实验成效。

演示视频为可选，时长不超过10分钟。

## P2 | 作品目标与实际完成内容

### 团队实际解决的问题

现有不足:端到端科研 agent 的失败集中在诚信与元认知而非执行力——ARFT 800 轨迹中 F.4(自知未纠仍提交)82.5%、E.2(无根据更新)78.1%、D.4(忽略已知问题)77.5%;其 rollout 提示词已要求全部认知动作且被执行,然后惰性——提示词路线的负结果。本作品解决其中"承诺装置缺失"一项:让假设迁移、观测落地、终局收口从模型裁量变为服务器结构。

### 本作品实际完成的工作

已实现:Prima 桌面产品 + Prime Agent 运行时适配(RLM 时机重写/双子会话/研究隔离)+ research-mcp 确定性认识论底座(95 测试)+ 认知层 skills(六移动+计数器)+ E1/E1M 十二臂评测 + ARFT 双列审计 + 确定性审计脚本 + 两轮闭环代表案例;未做:学习式 controller(明确定位为最小集成,后续实验见 P18)。

### 本作品形成的完整闭环




图1 五层架构与四条返回边(闭合来自不可绕过的边界)

【图1:五层架构与四条返回边——见插图】Prima 外壳→Prime 运行时→research-mcp(唯一认知 owner)→bwrap 沙箱→外部 meter;红色返回边 R1-R4 即反馈迭代通道。

本作品最终形成的主要输出:每臂可复算的研究战役(journal/prereg/REPORT/账本)、跨世界机制结论与反事实预报、ARFT 审计结论、两轮闭环演示 bundle 与 16 张 UI 实况截图、7 张图(架构/上下文/MSE/稳定性/ARFT/两轮/干预)。

本作品已经实际完成的实验、仿真或测试范围:NeuronBench 六世界 × 2 模型 × 全流程(seed 0,预算 8);两轮闭环案例(同世界 seed 0/1);ARFT 45 模式双列审计(6+6 轨迹,双判官);21 臂确定性审计复算。

相较一次性生成实验方案,本作品最主要的不同:判断必须是一次被验证器许可的状态迁移——无落地探针则假设不能迁移,无迁移则报告过不了 gate;"重新生成"不合法(demo2r 两轮实测:第二轮必须以第一轮债务清单为唯一起点)。

## P3 | 本作品采用的科学逻辑与实验判断

### 团队实际采用的判断原则

| 科学判断环节           | 本作品实际采用的做法                                                                                                    | 采用该做法的理由                                       |
|------------------|---------------------------------------------------------------------------------------------------------------|------------------------------------------------|
| 区分已有事实、工作假设与模型推断 | journal分账:观测(带噪)/候选模拟(免费)/预报评分(oracle)三类事件分离;假设状态机(H*/OPEN→SUPPORTED/CONTESTED/REFUTED/SCOPED),迁移必须引用落地探针(P#) | 状态混在上下文里是ARFT F6 状态失忆(重提已杀假设)的根源;账本分离让"已处决"可查询 |
| 将研究目标转化为可执行实验任务  | 阶段推导状态机+六移动卡(登记假设/预登记探针/执行/攻击/迁移/收口),不落账=没发生                                                                  | 把"想过了"与"做过了"分开,评审可逐卡对账                         |
| 明确预期观测和可证伪结果     | 每个假设必须给互斥频段对(H1带vs H0带)+kill/scope分支,零宽频段与常数回显被结构性拒绝                                                          | 无频段的"预期"不可否定(ARFT F3),频段使支持/否定都可机器判定           |
| 保留不确定性、异常和替代解释   | CONTESTED为合法终态;对抗阶段强制RLM子代理攻击LIVE假设,攻击落账(31条/臂级);graveyard逐条点名死因                                              | 单假设自确证是ARFT F4;强制对抗把替代解释变成账面义务                 |
| 根据实验结果决定继续、调整或停止 | 预算账本(超额拒绝)+终局契约(declare唯一合法收口,declare后世界关闭)+next_required_action邻近反馈                                          | 停止本身被定价:不自收口则无产出,乱收口则gate红                     |

本作品的科学逻辑

科学逻辑:已有证据(ARFT taxonomy+我们 12 臂 journal)支持"认知动作被执行但惰性、缺的是承诺装置";本轮实验判断:结构闸能否把惰性转化为拒绝-修复回路。支持观测:gate 拒绝事件真实发生且驱动修复(demo2r 两拒);诚信簇失败率坍塌(E2b 同判官)。削弱/否定观测:若换判官结论翻转则不可跨判官声称(已实测,故只取同判官对照);若叙事与账本漂移(gate 盲区)则以确定性审计为准。这些结果直接决定下一轮:债务清单进 REPORT,作为第二轮唯一起点。三态纪律:【证据】=journal 可复算;【推断】=归因表述;【待验】=plus@0.17.77 对照臂与消融阶梯。仿真世界结果不表述为真实实验。

P4 | 本作品实际使用的数据、资料与实验条件

已实际使用的内容

| 数据、资料、仪器或仿真条件                                                | 本作品如何实际使用                    | 对实验规划或结果判断的作用           | 已知局限                    |
|--------------------------------------------------------------|------------------------------|-------------------------|-------------------------|
| NeuronBench六世界部分观测电生理仿真(tbm/zreb/dtype/ca/hsag/nafat,seed 0) | 12臂×全流程机制发现+6协议held-out反事实预报 | 提供跨机制族的评价面(离子通道/疲劳/反弹等) | 仿真非真实实验,报告全程用"仿真世界"表述   |
| AutoResearchEval/ARFT 45失败模式taxonomy(800轨迹)                  | 六断裂归约(F1-F6)+E2/E2b 双列审计判官   | 定义"要消除的失败"并作为评价本体       | 模式级HIT强判官依赖(已实测并纳入口径)   |
| 外部计量器world-meter(预算8,flock账本)                                | 观测扣预算、候选模拟免费、forecast一次性评分   | 预算纪律可执行,oracle 不出沙箱     | 预算=探针数非token,粒度由meter定义 |
| ARFT判官语料(glm-5.3主判官+opus-5敏感性对照)                             | 同判官内跨条件比较;判官漂移实测入账           | 保证结论不因换判官翻转             | 判官非金标准,k一致性待深算          |

实际处理方法

团队如何检查输入数据或实验条件是否可用:输入检查分诊梯(单位/时基/缺失/冲突逐级拒绝);世界 info 查询与协议标签枚举;denylist fail-closed 禁读 world 源码;渠道健康巡检(session.log 模型签名,曾据此抓获 judge 别名漂移)。

单位、坐标、采样频率、时间基准等如何统一:协议标签由 world info 唯一发出(mA/ms/mV),模型不得自造标签;观测计数与预报同口径(spike 数);meter 统一时基与 reps 语义。

遇到数据缺失、条件不足或信息冲突时:结构闸拒绝而非补默认值——零宽频段/冲突分支被拒;探针 exit≠0 不予落地(崩溃与干净结果不可区分,一概拒绝);预算不足时拒超额观测,提示改用已落地观测收窄假设。

仪器或仿真环境的能力边界如何影响实验任务计划:预算 8+一次 forecast+终局后世界关闭,直接决定"选择不排序"的规划纪律与确证预留 ≥2 reps;oracle 封闭决定评价指标只能是 held-out 反事实预报。

P5 | 本作品采用的评价方法

实际评价方案

| 实际采用的评价内容         | 具体评价方法                                                   | 评价对象与样本          | 结果如何影响下一轮                |
|-------------------|----------------------------------------------------------|------------------|--------------------------|
| 反事实预报精度           | held-out协议spike数预报,world_forecast一次性MSE                  | 12臂(6世界×2模型)     | 定位误差来源(ca:低估反跳幅度→押注方向修正) |
| declare真调率+三道gate | journal事件+gate.verdict(程序判定,非自评)                         | 12臂全量            | gate红驱动修复回路(demo2r两拒实录)  |
| 过程诚信(ARFT)        | 同判官(glm-5.3)45模式HIT分类,臂间对照                               | E1 vs E1M(n=6+6) | 诚信簇坍塌→定位到具体闸(回显/终局契约/对账) |
| 确定性审计             | journal_metrics.py零LLM复算:prereg重哈希/REPORT sha/MSE引用/催促计数 | 全部bundle(评委可重跑)  | 审计发现如实入账(E1催促日志缺口不造数)    |

评价口径说明

团队重点评价哪些科学结果、计划质量或执行表现,为什么:①反事实预报 MSE(机制认识的唯一外部出口);②declare 真调率+gate(收口真实性);③ARFT 过程诚信(与 SOTA taxonomy 可比);④确定性审计(以上全部可复算)。

评价主体:meter/gate/审计脚本=程序;ARFT 判官=模型(次级诊断);agent=被评对象;人=不参与逐臂评分,只做事故台账与披露。

第一轮与第二轮是否采用同一口径:是——同世界/同预算/同 gate/同审计脚本;唯一差异 seed 0→1(防背答案),故 MSE 跨轮不直比,过程指标(gate/预算/prereg 时序/债务处置)同口径对照。

什么情况下继续/调整/停止/交由人:频段内支持→迁移假设;频段外→处决或 CONTESTED;预算尽→收口 declare;gate 红→修复回路;基础设施事故(欠费/容器)→人工修复+中性唤醒(台账留痕);其余全部 agent 自主。

P6 | 系统总体架构与技术闭环

本作品真实架构




图2 真实一回合的六层上下文注入结构(journal replay→锚)

【图1:五层架构与四条返回边——见插图】Qwen 位于运行时层(会话唯一对话方),人工参与仅限基础设施事故(台账留痕),结构闸与三道 gate 位于模型不可绕过的 research-mcp 层。

| 实际模块       | 输入             | 本作品的核心处理                           | 输出                    | 与下一模块的关系                   |
|------------|----------------|------------------------------------|-----------------------|----------------------------|
| 研究目标与约束理解  | 任务目标+世界info+预算 | Qwen+research-loop skill推导阶段与假设树起点 | 假设清单+计划(PPLAN/prereg) | 假设须登记才可被探针引用               |
| 实验任务规划     | 假设树+频段预测       | 预登记探针(判别力/成本,不排序;kill/scope分支)     | 冻结的探针spec(sha256)     | 只有冻结命令可执行                  |
| 实验或仿真执行    | 冻结spec         | bwrap沙箱执行+计量器观测(扣预算)/候选模拟(免费)      | raw观测+probe.land      | 全部进journal,含失败(exit≠0不予落地) |
| 数据分析与结果判断  | raw+频段         | 服务端重算指标+频段判定;RLM子代理对抗攻击            | claim迁移/攻击落账          | 迁移必须引用P#,无落地探针不迁移          |
| 反馈与下一轮计划调整 | 未清偿债务清单        | REPORT 「遗留与债务」段→下一轮唯一起点            | 债务清单+两轮对比             | 第二轮以此开局(demo2r实测)          |

技术闭环的关键设计

为什么不是一次性生成:四条返回边实测在案——R1 gate 拒绝声明驱动修复(demo2r reconcile 拒+prereg 拒);R2 预算超额拒绝;R3 journal replay 重推导状态(锚);R4 next\_required\_action 邻近反馈防长上下文遗忘。真实结果回到哪个环节:观测→频段判定→假设迁移;拒绝理由→报告修复;债务清单→下一轮计划(唯一入口)。

P7 | Qwen使用方式与上下文工程

Qwen在本作品中的实际作用

| 内容                    | 本作品实际做法                                                                       |
|-----------------------|-------------------------------------------------------------------------------|
| 使用的Qwen模型与调用方式        | qwen3.7-plus(E1)与qwen3.8-max(E1M):百炼DashScope直连;演示:百炼TokenPlan端点;渠道级隔离,每臂独立容器 |
| Qwen承担的具体任务           | 假设提出与频段预测/探针设计与命令生成/对抗攻击子代理/报告与declare;运行时负责一切状态与裁决                           |
| 一次规划或调整时提供给模型的上下文     | 六层:静态契约→终局契约→环境注入→状态推导skills→内核锚(register摘要)→轨迹(可压缩)                          |
| 结构化输出或格式约束            | 工具schema强类型;journal事件为唯一落账格式;REPORT须含「遗留与债务」段;无自由文本状态                         |
| 与仪器、仿真、分析代码或其他工具的协作方式 | world_*MCP(计量)/research_*MCP(账本)/文件工具;分析命令仅沙箱执行冻结串,stdout-only                |

上下文组织




图3 两轮闭环 UI 实况:第二轮 declare 一次过门(第一轮两拒后修复)

【图2:真实一回合的六层上下文注入结构——见插图】静态契约→终局契约→环境注入→状态推导 skills→内核锚(register 摘要)→轨迹(可压缩);journal(磁盘)经 replay 推导锚,拒绝信息作为新回合上下文重注入。  
减无依据措施:状态只从 journal 推导(锚),页面/对话文本不可信;数字必须有(P#)出处否则 reconcile 拒;已处决假设 graveyard 防复活;对抗子代理强制攻击 LIVE 假设。  
上下文更新:每回合运行时注入环境刷新;register 快照→内核锚随每次落账更新;轨迹可压缩可丢,journal 永不丢——上下文任何部分丢失后信念态可由 journal 重建。  
实际变化:ARFT 诚信簇 93-100%→0-33%(同判官);12/12 臂自主收口;两轮案例中第二轮一次过门(第一轮两拒)。

P8 | 实验任务规划方法

本作品实际采用的规划过程



| 规划环节         | 本作品实际做法                                     | 形成的中间结果                           | 对执行的具体作用                         |
|--------------|---------------------------------------------|-----------------------------------|----------------------------------|
| 将研究目标拆解为实验任务 | 机制发现→反事实预报两目标拆为六阶段状态机(取题/假设/预登记/执行/对抗/终局)   | 假设树+探针队列                          | 每步有唯一合法下一步(next_required_action) |
| 确定任务依赖和执行顺序  | 选择不排序:预测结果表(各探针在两假设下的预期读数),按判别力/成本取用        | 预测结果表(冻结于prereg)                  | 判别力优先,预算约束下贪心                    |
| 选择参数、资源和实验条件 | 协议标签来自world info;reps按方差需求;预算8内预留确证≥2       | 冻结spec(protocol/reps/evalCommand) | 执行器只认冻结参数                        |
| 检查约束冲突与可执行性  | 互斥频段/kill分支/零宽/回显/方向倒置/预算flock六道结构闸,装饰性探针拒绝 | 闸判定(拒绝理由文本)                       | 拒绝即反馈,模型修复后重试                    |
| 设置预期观测和停止条件  | 每假设频段对即停止判据;终局契约:declare是唯一合法收口,终局后世界关闭     | 频段+终局契约                           | 防无判据续跑与无声明收场                     |

实际计划输出

[请展示一份本作品真实生成的计划片段，说明每项任务包含哪些内容，以及计划如何交给实验、仿真或人工环节执行。]

## P9 | 实验或仿真实际执行与数据获取

本作品实际完成的执行过程

| 实际执行环节 | 使用的仪器、仿真或工具                           | 输入与主要参数           | 获得的原始结果             | 结果如何进入后续分析                 |
|--------|---------------------------------------|-------------------|---------------------|----------------------------|
| 计量观测   | world_observe(外部meter,预算8)            | 协议标签+reps         | 带噪spike计数+降采样电压     | journal world.observe→频段判定 |
| 候选机制对比 | world_simulate(免费)                    | 机制spec(extra电流参数) | 参考vs候选计数差           | 筛假设,不扣预算                   |
| 沙箱探针   | probe_run(bwrap:只读FS/无网络/stdout-only) | 冻结evalCommand     | metric或exit≠0(不予落地) | 失败也落账,可审计                  |

执行说明

执行前实际进行了哪些输入、单位、范围或安全检查：\_\_\_\_\_

原始结果如何保存并与模型生成内容区分：\_\_\_\_\_

如同时使用真实仪器和仿真，二者分别承担什么作用：\_\_\_\_\_

实际执行范围之外的内容，是否由人工或离线方式完成：\_\_\_\_\_

## P10 | 数据分析、质量控制与反馈形成

本作品实际采用的分析过程

| 分析环节     | 实际输入              | 方法与主要参数          | 得到的结果            | 质量或不确定性判断       | 如何形成反馈 |
|----------|-------------------|------------------|------------------|-----------------|--------|
| 数据预处理    | raw观测(服务端捕获)      | 直接入journal,不改写   | 事件流              | 单一事实源           |        |
| 结果计算或识别  | probe.land metric | 服务端从raw重算,不信模型自报 | 指标值              | (P#)对账进REPORT   |        |
| 异常值与质量判断 | 观测vs频段            | 频段外=判别信号而非噪声     | 支持/否定/不可判别       | 驱动假设迁移或新探针      |        |
| 与预期结果比较  | 预测结果表             | 逐探针比对预期读数        | 差异归因(如ca:低估反跳幅度) | 写入REPORT校准段与债务段 |        |

结果如何变成反馈

哪些原始结果直接进入反馈：\_\_\_\_\_

哪些内容由确定性程序计算，哪些由模型解释：\_\_\_\_\_

团队如何避免仅凭大模型主观判断关键实验结果：\_\_\_\_\_

人工复核实际发生在哪些环节：\_\_\_\_\_

## P11 | 本作品实际采用的反馈与计划调整方法

已实现或实际使用的反馈机制

| 实际反馈信号                  | 系统如何识别                               | 对当前结果的判断        | 下一轮实际调整            | 调整理由        |
|-------------------------|--------------------------------------|-----------------|--------------------|-------------|
| gate红(reconcile:数字无出处)  | report_declare当庭校验REPORT数字→journal出处 | 报告不可信部分被逐条点名    | 补实验或改报告后重declare   | 拒绝理由即修复指令   |
| gate红(prereg:空run无落地探针) | 账本检查:无落地探针则声明无效                      | 观察走计量路径≠探针落地    | 改走prereg→probe_run | 类型边界实测生效    |
| 频段外观测                   | 频段判定                                 | 假设被否定或CONTESTED | graveyard+新假设登记    | 死因入账防复活(F6) |
| 预算超额                    | meter拒绝对超额观测                         | 预算内收窄而非硬闯       | 改用已落地观测/免费模拟       | 预算纪律强制      |

一项真实调整示例

[请用 一个简短例子说明：第一轮的哪项实际结果触发了什么判断，系统因此将下一轮的哪项任务、参数、顺序、数据获取方式或停止条件由什么改为什么。]

P12 | 完整运行流程与实际失败处理

一次完整运行

[请插入本作品真实工作流程图，展示从接收研究目标到形成下一轮计划的全过程，并标明反馈返回到哪个环节、何时停止或转由人工处理。]

本作品实际出现或主动测试过的情况

| 实际情况                  | 系统发现了什么问题         | 本作品采取的处理                   | 对后续计划或结论的影响  |
|-----------------------|-------------------|----------------------------|--------------|
| 百炼欠费中断(E1M运行中)        | 臂心跳停;journal时序断点  | 充值后中性唤醒"继续"                | 6/6臂自主恢复并双绿  |
| judge模型别名漂移(opus-5混入) | session.log模型签名巡检 | 隔离语料重判(6/6重跑glm-5.3)       | 结论只取同判官内对照   |
| 评审容器沙箱权限缺失(demo2r)    | 探针全exit 1(id也败)   | 定位缺CAP_SYS_ADMIN→重建容器(卷保留) | 会话无损续跑,事故入账账 |

哪些情况由系统自动处理：\_\_\_\_\_

哪些情况必须由研究者或实验人员判断：\_\_\_\_\_

团队如何保留处理前后的真实变化：\_\_\_\_\_

P13 | 代表性案例选择与实际设置

为什么选择这个案例

案例对应的科学问题与实验目标：\_\_\_\_\_

团队选择它进行完整展示的实际理由：\_\_\_\_\_

该案例能够展示本作品的哪些关键能力：\_\_\_\_\_

该案例表现不能代表哪些任务或条件：\_\_\_\_\_

案例的实际初始条件

| 内容           | 本案例实际情况                                                                       |
|--------------|-------------------------------------------------------------------------------|
| 已有证据或初始数据    | 第一轮:仅world info(协议标签+预算)+3次免费info查询;不读真值                                      |
| 实验对象、仪器或仿真条件 | NeuronBench ca_rebound(钙反弹世界),seed 0(第一轮)/seed 1(第二轮),计量预算8,denylist禁读world源码 |
| 可控变量与主要约束    | 协议(条件化深度/时长/测试脉冲)/reps/候选机制参数;约束:预算8、prereg先行、declare唯一收口                     |
| 第一轮希望获得的观测结果 | 区分"额外电流是何机制"(T型钙vs慢K失活vs ICAN等),并给6协议held-out计数预报                             |
| 第一轮评价方法      | world_forecast MSE(oracle)+三道gate+journal_metrics确定性审计                        |

P14 | 第一轮实验任务计划

第一轮实际计划

| 步骤 | 实际任务或动作                                              | 主要参数                      | 前置条件            | 预期观测             | 资源或耗时    | 停止或调整条件       |
|----|------------------------------------------------------|---------------------------|-----------------|------------------|----------|---------------|
| 1  | research_init(run=demo2r-ca-r1)+读research-loop skill | seed 0,预算8                | skill可用,run目录建立 | 假设树+PLAN         | 约3分钟     | skill缺失即停     |
| 2  | 候选机制免费对比(world_simulate)                             | 机制spec若干                  | 参考vs候选计数差       | 筛选后假设清单          | 免费不扣预算   | 无判别力即弃        |
| 3  | 预登记判别探针(prereg_write冻结sha256)                        | protocol/reps/evalCommand | spec冻结(不可改)     | 频段对+kill/scope分支 | 每探针1-3预算 | 装饰性探针被拒       |
| 4  | 执行(observe/probe_run)+对抗(RLM攻击LIVE)                  | 冻结参数                      | 带噪观测+攻击落账       | claim迁移依据(P#)    | 预算8内     | 预算尽→收口declare |

计划形成过程

第一轮使用了哪些研究目标、证据和约束：\_\_\_\_\_


Qwen和其他模块分别完成了什么：\_\_\_\_\_

团队如何检查计划是否能够实际执行：\_\_\_\_\_

人工是否修改了计划；如有，修改了什么、为什么：\_\_\_\_\_

P15 | 第一轮实验执行与结果

图6 · 两轮闭环对照(demo2r-ca,qwen3.7-plus@百炼 TokenPlan,journal 真值)



审计:两轮 gate 全绿;prereg 重哈希 12/12 与 4/4;REPORT sha 一致。两轮报告叙事表(claim 状态)与 journal 存在漂移——gate 校数字出处、不校叙事,差异已在 NOTES 如实记录。

图4 两轮闭环对照(journal 真值,脚本可复算)

第一轮实际执行

| 步骤 | 实际动作与参数                 | 获得的原始结果 | 质量检查      | 与预期的差异    | 耗时或资源          |
|----|-------------------------|---------|-----------|-----------|----------------|
| 1  | 15次候选模拟筛选机制族            | 免费      | 参考vs候选差异  | journal完整 | 3假设存活          |
| 2  | 5次计量观测+频段判定             | 扣预算5/8  | 带噪计数      | (P#)对账    | H1支持/H2争议/H3处决 |
| 3  | forecast提交(6协议一次性)      | 不可重复    | MSE=6.595 | oracle评分  | 梯度结构对,幅度偏差→债务  |
| 4  | report_declare→两拒→修复→过门 | gate三联  | 拒绝理由×2+修复 | sha256冻结  | 12后补prereg全落地  |

第一轮实际评价



| 实际评价内容    | 评价口径           | 第一轮结果                      | 是否达到预期 | 不确定性或误差                        |
|-----------|----------------|----------------------------|--------|--------------------------------|
| 反事实预报MSE  | 6协议平方误差        | 6.595(qwen3.8-max同世界35.53) | 部分达到   | 释放协议幅度低估约一倍(预报12-17,真值10-14区间) |
| declare真调 | journal事件+gate | 过门(两拒后)                    | 达到     | 修复回路多耗12个后补prereg              |
| 预算纪律      | meter账本        | 11/8超支                     | 未达到    | 候选模拟reps计费语义待澄清→入债务            |

P16 | 第一轮问题分析与调整依据

团队实际发现的问题

| 第一轮具体结果或问题              | 判断依据                   | 可能原因与替代解释              | 对下一轮的影响             | 第二轮实际调整  |
|-------------------------|------------------------|------------------------|---------------------|----------|
| 释放协议幅度低估(预报12-17)       | forecast MSE分解+grill攻击 | 慢内向成分(ICAN/INaP)未被机制覆盖 | 第二轮登记H3=ICAN并设计判别探针 | 债务清单驱动   |
| H1频段过宽[35,60]判别力弱       | G系列攻击指出                | 频段宽=支持但不判别             | 收紧至[36,44]          | 可否证性提升   |
| prereg时序纪律未先行(0先行,12后补) | journal时间戳审计           | 修复回路补登                 | 第二轮硬性要求先行           | P14证据链加强 |

调整逻辑

哪项实际结果、评价或人工意见触发了调整：\_\_\_\_\_

第二轮增加、删除、重排或改变了什么：\_\_\_\_\_

哪些任务或参数保持不变，为什么：\_\_\_\_\_

团队预期第二轮在哪些方面改善：\_\_\_\_\_

P17 | 第二轮实验计划、执行与结果

第一轮与第二轮的实际变化

| 变化内容    | 第一轮          | 第二轮                             | 变化原因       | 第二轮实际结果                                        |
|---------|--------------|---------------------------------|------------|------------------------------------------------|
| 任务内容与顺序 | 自由探索→两拒→修复   | 以债务清单为唯一起点(登记/驳回ICAN+收紧H1+判别探针) | 反馈迭代而非重新生成 | 一次过门(不再被拒)                                     |
| 参数与实验条件 | seed 0       | seed 1(防背答案:机制信念作先验须重校准)        | 跨seed迁移测试  | 梯度结构保持;long step 26→33重校准;MSE 14.33(跨seed不可直比) |
| 数据获取方式  | 5计量观测+15免费模拟 | 4预登记→4观测+4沙箱探针(0失败)             | 先冻结后执行     | held-out 6/6全部未模拟=纯泛化                          |
| 分析与判断方法 | gate两拒驱动修复   | 同口径+两轮对比段                       | 债务逐条对账     | 预算✓/频段部分✓/ICAN登记✓/H2未决(如实)                     |
| 停止或继续条件 | 预算尽收口        | 同+债务未清偿项如实列为遗留                  | 终局契约不变     | H1以收紧带复确证(SUPPORTED)                           |

第二轮结论

第二轮实际改善了什么：\_\_\_\_\_

哪些方面没有改善或出现了新的代价：\_\_\_\_\_

两轮结果是否支持最初的科学判断，依据是什么：\_\_\_\_\_

团队为什么在此时停止，或为什么仍需继续迭代：\_\_\_\_\_

“无提升”同样是有效实验结果，但应分析原因，不能只展示成功迭代。

P18 | 实际对照、消融与方案优势

图7 · 干预前后确定性计数(E1@0.17.76 → E1M@0.17.77;journal\_metrics.py可复算)




图5 干预前后确定性计数(declare 收口 9/15→6/6;E1 催促缺口如实标注)

团队实际完成的比较

| 实际比较对象                                                   | 保持相同的条件            | 采用的评价方法                           | 本作品结果                                                           | 对照结果                                                            | 结论与代价                                         |
|----------------------------------------------------------|--------------------|-----------------------------------|-----------------------------------------------------------------|-----------------------------------------------------------------|-----------------------------------------------|
| qwen3.8-max@0.17.77 vs qwen3.7-plus@0.17.76(同世界/seed/预算) | 六世界,seed 0,预算8,同流程 | world_forecast MSE+gate+ARFT(同判官) | 38max:tbm 0.035/zreb 2.42/dtype 1.43优;ca 35.5/hsag 37.3劣;nafat平 | plus:tbm 14.98/zreb 202/dtype 20.0;ca 9.2/hsag 10.7;nafat 175.7 | 模型画像不同而非强弱;混杂:模型与栈双变量(plus@0.17.77对照臂待跑,如实声明) |
| 结构闸前后(E1 vs E1M, 同判官ARFT)                                | n=6+6,glm-5.3      | 45模式HIT                           | 诚信簇 (D.4/E.2/F.4/C.1)0-33%                                      | 93-100%                                                         | F.4(自知未纠)清零;归因对应回显闸/终局契约/(P#)对账               |
| 确定性审计(评委可复算)                                             | 全部bundle           | journal_metrics.py零LLM            | prereg重哈希40/40、REPORT sha 6/6、催促如实计数                            | —                                                               | E1催促日志未归档,不造数                                 |

结果说明

科学逻辑方面，本作品实际改善了什么：\_\_\_\_\_

技术方法方面，本作品实际改善了什么：\_\_\_\_\_

结果表现方面，本作品实际改善了什么：\_\_\_\_\_

没有改善的部分及增加的成本：\_\_\_\_\_

P19 | 总体结果、失败分析与适用边界




图6 12 臂六世界 MSE 对照(模型×栈两列)

本作品实际总体表现

| 实际测试或实验范围          | 完成的闭环轮次或样本          | 主要评价结果                         | 重复运行表现               | 仍存在的问题                |
|--------------------|---------------------|--------------------------------|----------------------|-----------------------|
| 12臂×六世界×全流程+两轮闭环案例 | 12臂declare全绿;两轮闭环双绿 | MSE 0.035~178.7;诚信簇坍塌;两轮预算11→4 | 欠费中断后6/6自主恢复;容器重启后双绿 | 单seed;双变量混杂;叙事漂移(P17) |
| ARFT双判官语料          | 6轨迹×2判官             | 模式级HIT 15.6 vs 12.7;诚信簇天花板vs崩塌 | 判官敏感性实测              | 结论只取同判官内对照            |
| 确定性审计复算            | 21臂bundle           | prereg重哈希102/102(62+40)        | 脚本一行复跑               | E1催促日志缺口如实标注          |

真实失败与边界

| 典型失败或边界问题 | 实际表现                                  | 原因分析               | 目前能够做到的程度                |
|-----------|---------------------------------------|--------------------|--------------------------|
| 叙事-账本漂移   | r2报告claim状态表与journal不符(H1实为SUPPORTED) | reconcile校数字出处不校叙事 | 确定性审计为准;纳入reconcile列为工程项 |
| 判官依赖      | 同批轨迹换判官结论翻转                           | 模式级HIT非金标准         | 同判官内对照+敏感性披露             |
| 计划文件未落盘   | PLAN-v1/v2两轮均未写                       | 模型行为习惯,提示未强制       | P14证据退回prereg时间戳链(如实)    |

本作品能够服务的真实用户和实验环节：\_\_\_\_\_

相比现有方式节省或增加了哪些成本：\_\_\_\_\_

必须由研究者决定、审批或承担责任的事项：\_\_\_\_\_

尚不能支持的任务、仪器、数据或部署范围：\_\_\_\_\_

P20 | 代码复现与提交材料




图7 百炼调用凭证:6,143 次调用/3.96 亿 token/7 模型全 Qwen 族(08-21→27)

最终交付内容

| 交付项目                 | 实际提交内容或入口                                                                                                                |
|----------------------|--------------------------------------------------------------------------------------------------------------------------|
| 源代码、环境、依赖与运行方法       | github.com/CrepuscularIRIS/crucible(主分支;提交记录即时间戳证据);compose一键冷启+复现包(含容器权限参数说明);research/eval/下全套脚本                       |
| Qwen模型、调用方式及凭证或截图    | 百炼调用凭证截图:6,143次/3.96亿token/7模型全Qwen族,08-21→27(docs/imgs/image.png);TokenPlan套餐用量页截图待补;报名表盖章页×2见P1                        |
| 代表案例的输入、两轮计划、结果和必要日志 | research/campaigns/demo2r-2026-08-28-ca/round{1,2}/:run/(journal+prereg+REPORT+账本)+双视角session日志;16张UI实况截图(shots/demo2r/) |
| 总体测试或实验结果材料          | E1/E1M 12臂bundle+SCORE;ARFT双列审计语料;T-metrics审计表;journal_metrics.py一行复算                                                    |
| 测试API、示例请求与可交互前端     | web-bridge WS协议(invoke/reply)+agent/settings通道文档与示例(复现包内);前端:Proma桌面UI,每臂独立容器演示(demo2r容器5211端口保留可现场演示)                   |
| 可选演示视频               | 【录制后填夸克链接】≤10分钟:两轮闭环实录(含gate两拒片段)                                                                                        |

提交前自检

- ☐ 技术方案PPT/PDF不超过20页，正文内容与本作品实际实现一致。
- ☐ 代表案例真实呈现第一轮计划、执行结果、调整依据和第二轮变化，没有用重新生成代替反馈迭代。
- ☐ 科学判断、技术方法、实际结果和方案优势之间能够相互对应，未省略失败、未改善部分和适用边界。

☐ 源代码、运行说明、Qwen调用凭证、代表案例材料、测试API和前端入口可以正常核验。

☐ 未将仿真结果或模型判断表述为已经完成真实科学验证；受限数据、密钥和个人信息已妥善处理。